

CoopInfer: 边端协同推理调度原型

面向 DAG 切分、约束求解与时序可视化的桌面验证工具

CoopInfer 项目

2026 年 6 月 23 日

- 具身智能系统常由感知、融合、控制等算子组成，并形成 DAG。
- 部分算子必须固定在机器人端侧设备，部分算子可以卸载到边侧主机。
- 真实调度不仅是图切分：
 - 跨设备边会产生网络传输代价；
 - 端侧和边侧都有有限执行队列；
 - 端到端时延上限会直接排除不可行方案。
- CoopInfer 用于快速编辑、求解、验证并可视化这类调度方案。

输入

- DAG 节点及端侧/边侧执行耗时。
- 边数据量。
- 带宽、固定时延、优化权重。
- 可选端到端时延上限。

输出

- 节点放置决策: $x_i = 0$ 表示端侧, $x_i = 1$ 表示边侧。
- 端到端时延和端侧算力利用率。
- SVG 拓扑图和 profiler 风格时序图。

- 内存中使用 `networkx.DiGraph` 存储拓扑。
- 节点属性：
 - `id`, `name`, `c_dev`, `c_host`, `fixed_dev`, `x`
- 边属性：
 - `source`, `target`, `size`, 单位为 MB。
- 环境参数：
 - `bandwidth`, `latency`, `weight_latency`, `latency_limit`
- JSON 导入/导出保证实验可复现、可共享。

内层解析器：数据依赖与资源排队

对 DAG 按拓扑序遍历。对节点 i :

$$DataReady_i = \max_{j \in pred(i)} \left(F_j + \mathbb{I}(x_j \neq x_i) \left(L + \frac{S_{ji}}{B} \right) \right)$$

数据就绪后，还要等待目标设备队列空闲：

$$S_i = \begin{cases} \max(DataReady_i, time_dev_ready), & x_i = 0 \\ \max(DataReady_i, time_host_ready), & x_i = 1 \end{cases}$$

$$F_i = S_i + (1 - x_i)c_i^{dev} + x_i c_i^{host}$$

端到端闭环时延为 $\tau = \max_i F_i$ 。

优化目标与可行性约束

求解器最小化加权目标：

$$J = w \cdot \frac{\tau - \tau_{min}}{\tau_{max} - \tau_{min}} + (1 - w) \left(1 - \frac{\sum_i (1 - x_i) c_i^{dev}}{\sum_i c_i^{dev}} \right)$$

端到端时延上限

正数 `latency_limit` 是硬约束：

$$\tau \leq \textit{latency_limit}$$

超过上限的候选方案会在目标函数比较前被直接拒绝。

求解模式

模式	适用场景	行为
Auto	默认模式	自由节点 ≤ 12 时枚举，否则随机搜索
Enumerate	小规模 DAG	遍历所有方案，返回全局最优可行解
Random Search	较大 DAG	随机扰动放置方案，保留最佳可行候选
Simulated Annealing	跳出局部最优	按温度接受部分更差移动

所有模式都会强制固定端侧节点，并执行端到端时延上限过滤。

GUI 使用流程

- ① 编辑节点、名称、计算耗时和固定端侧标记。
- ② 编辑边和传输数据量。
- ③ 配置带宽、固定时延、优化权重、求解模式、迭代次数和端到端时延上限。
- ④ 点击 **Solve**。
- ⑤ 查看性能看板、拓扑放置和 profiler 风格时序图。

系统会校验重名节点、非法边端点以及非 DAG 拓扑。


拓扑 SVG

- 蓝色：端侧。
- 绿色：边侧。
- 加粗边框：固定端侧节点。
- 红色虚线边：跨设备传输。
- 灰色实线边：同侧依赖。

时序 SVG

- Host、Transfer、Device 三条泳道。
- 算子条由开始/完成时间决定。
- 传输条由网络传输耗时决定。
- 使用浏览器原生滚动和缩放控件。

示例 DAG



解析器输出的是考虑设备队列的真实调度，而不是理想无限并行关键路径。

- Python 3.9+。
- PyQt6 负责桌面控件和布局。
- PyQt6-WebEngine 负责 SVG 拓扑图和时序图渲染。
- NetworkX 负责 DAG 存储、拓扑排序和环路检测。
- Pytest 覆盖解析器、JSON IO、求解模式和时延上限可行性。

- 增加求解诊断：被拒绝候选、约束裕量、收敛历史。
- 支持拓扑图和时序图导出为 SVG/PNG 报告。
- 增加带宽/时延参数扫描的批量评估。
- 为大规模 DAG 引入更高级的调度算法。
- 在时序图中显式区分队列等待、数据就绪和传输阶段。

Q&A